

EXP 3

- Gabriel Tavares - 10773801
- Guilherme Reis - 10773700

```

▶PlotlyBackend()
* begin
*   using DSP ✓
*   using Plots ✓
*   using LinearAlgebra ✓
*   plotly()
* end

```

1) Simulação do filtro de 2 coeficientes

Parâmetros de simulação

```

* begin
*   N = 200
*   realizacoes = 100
*    $\sigma_x^2 = 1$ 
*    $\sigma_v^2 = 0.01$ 
*   noprint
* end

```

Simulação

```

* begin
*   M = 2
*   w_lms1 = zeros(N, M)
*   erro1 = zeros(N)
*
*   h1 = [1, -0.5]
*    $\mu = 0.05$ 
*   for realizacao in 1:realizacoes
*       x = randn(N)*sqrt( $\sigma_x^2$ )
*       v = randn(N)*sqrt( $\sigma_v^2$ )
*       y = filt(h1, x)
*       d = y .+ v
*       w, erro = LMS(x, d, M,  $\mu$ )
*       w_lms1 += w
*       erro1 += erro.*erro
*   end
*
*   w_lms1 = w_lms1./realizacoes
*   erro1 = erro1./realizacoes
*   noprint
* end

```

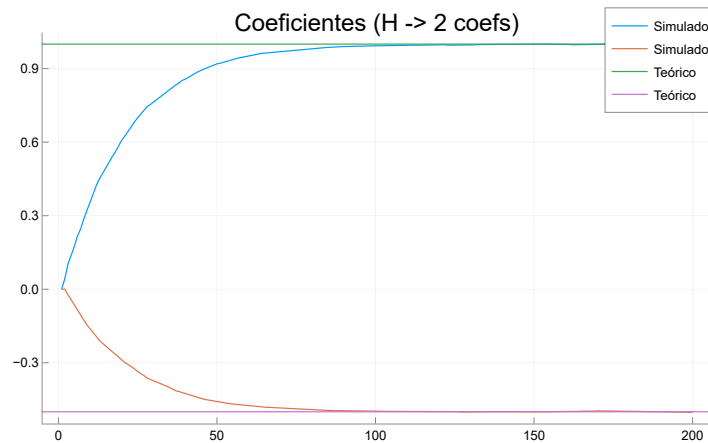

Valores teóricos

```

* begin
*   R $\phi$ 1 = [ $\sigma_x^2$  0;
*           0  $\sigma_x^2$ ]
*   rd $\phi$ 1 = [h1[1]* $\sigma_x^2$ , h1[2]* $\sigma_x^2$ ]
*   K1 = [ $\mu*\sigma_v^2/2$  0;
*          0  $\mu*\sigma_v^2/2$ ]
*   w $\phi$ 1 = inv(R $\phi$ 1)*rd $\phi$ 1
*
*   EMSE = tr(R $\phi$ 1*K1)
*
*   noprint
* end

```

Comparação de valores simulados e teóricos



Como esperado, os valores simulados e teóricos são bastante próximos. Como o filtro ideal e LMS tem 2 coeficientes, os coeficientes finais tendem para o filtro ideal

2) Simulação com filtros de 1 e 3 coeficientes

Simulação 1 coeficiente

```
begin
    # M = 2
    w_lms2 = zeros(N, M)
    erro2 = zeros(N)

    h2 = [1]
    # μ = 0.1
    for realizacao in 1:realizacoes
        x = randn(N)*sqrt(σx2)
        v = randn(N)*sqrt(σv2)
        y = filt(h2, x)
        d = y .+ v
        w, erro = LMS(x, d, M, μ)
        w_lms2 += w
        erro2 += erro.*erro
    end

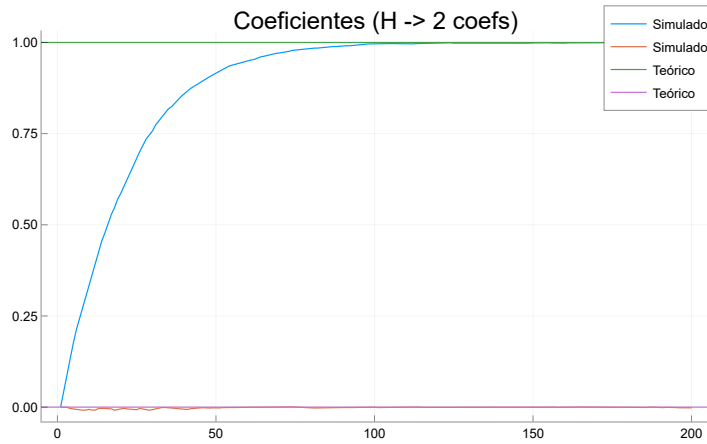
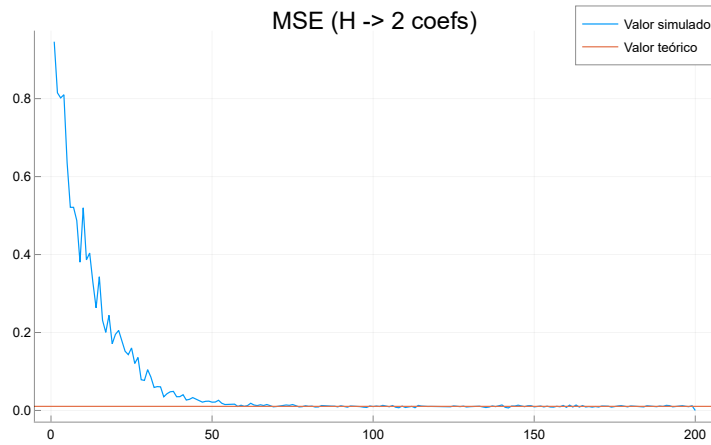
    w_lms2 = w_lms2./realizacoes
    erro2 = erro2./realizacoes
    noprint
end
```

Valores teóricos

```
begin
    Rφ2 = [σx2 0;
           0 σx2]
    rdφ2 = [h2[1]*σx2, 0]
    K2 = [μ*σv2/2 0;
          0 μ*σv2/2]
    w_o2 = inv(Rφ2)*rdφ2
    EMSE2 = tr(Rφ2*K2)

    noprint
end
```

Comparação de valores simulados e teóricos



Simulação 3 coeficientes

```

begin
    # M = 2
    w_lms3 = zeros(N, M)
    erro3 = zeros(N)

    h3 = [1, -0.5, 0.2]
    # μ = 0.1
    for realizacao in 1:realizacoes
        x = randn(N)*sqrt(σx2)
        v = randn(N)*sqrt(σv2)
        y = filt(h3, x)
        d = y .+ v
        w, erro = LMS(x, d, M, μ)
        w_lms3 += w
        erro3 += erro.*erro
    end

    w_lms3 = w_lms3./realizacoes
    erro3 = erro3./realizacoes
    noprint
end

```

Valores teóricos

```



begin
    Rφ3 = [σx2 0;
           0 σx2]
    rdφ3 = [h3[1]*σx2, h3[2]*σx2]
    K3 = [μ*σv2/2 0;
          0 μ*σv2/2]
    w_o3 = inv(Rφ2)*rdφ3

    EMSE3 = tr(Rφ2*K2)

    noprint
end

```

Comparação de valores simulados e teóricos



Usando um filtro ideal de 2 e 3 coeficientes, vemos que no primeiro caso no o algoritmo converge pra um resultado bom e se mantém na faixa de valores teóricos de EMSE. O primeiro coeficiente do filtro tende ao coeficiente do filtro ideal.

Com 3 coeficientes, o filtro LMS tenta chegar no valor mais próximo possível do filtro real, mas tem uma limitação de projeto de atingir o filtro ideal. Devido a isso, o seu valor de erro não na convergência fica a cima do valor teórico

3) Simulação do filtro adaptativo de 5 coeficientes e o filtro real de 2

Simulação

```
begin
    M5 = 5
    w_lms4 = zeros(N, M5)
    erro4 = zeros(N)

    h4 = [1, -0.5]
    # μ = 0.1
    for realizacao in 1:realizacoes
        x = randn(N)*sqrt(σx2)
        v = randn(N)*sqrt(σv2)
        y = filt(h4, x)
        d = y .+ v
        w, erro = LMS(x, d, M5, μ)
        w_lms4 += w
        erro4 += erro.*erro
    end

    w_lms4 = w_lms4./realizacoes
    erro4 = erro4./realizacoes
    noprint
end
```

Valores teóricos

```


begin
    Rφ5 = [σx² 0 0 0 0;
           0 σx² 0 0 0;
           0 0 σx² 0 0;
           0 0 0 σx² 0;
           0 0 0 0 σx²;
           ]
    rdφ5 = [h4[1]*σx², h4[2]*σx², 0, 0, 0]
    K5 = [μ*σv²/2 0;
          0 μ*σv²/2]
    w_5 = inv(Rφ5)*rdφ5

    EMSE5 = tr(Rφ2*K5)

    noprint
end

```

Comparação de valores simulados e teóricos



UndefVarError: w_4 not defined

1. top-level scope @ Local: 4

```

begin
    plot(title= "Coeficientes (H -> 2 coefs)")
    plot!(w_lms4, label="Simulado")
    hline!(w_4[1], label="Teórico")
    hline!(w_4[2], label="Teórico")
end

```

Nesse exemplo, como esperado o filtro LMS consegue convergir para os valores ideais e teóricos, por ter coeficientes suficiente para representar o filtro

4) Filtrando $x[n]$ antes da adaptação

Aqui estamos usando sinal de entrada $x[n]$ mais complexo do que apenas um ruído gaussiano

Simulação

```



begin
    N2 = 7.000
    w_lms5 = zeros(N2, M)
    w_lms6 = zeros(N2, M)
    w_lms7 = zeros(N2, M)
    erro5 = zeros(N2)
    erro6 = zeros(N2)
    erro7 = zeros(N2)

    realizacoes2 = 1.000

     $\sigma_u^2 = 1$ 
    h5 = [1, -0.5]
    h6 = [1]
    h7 = [1, -0.5, 0.2]
    a = 0.9
    g = PolynomialRatio([sqrt(1-a^2)], [1, -a])
     $\mu_2 = 0.01$ 
    for realizacao in 1:realizacoes2
        global w_lms5
        global w_lms6
        global w_lms7
        global erro5
        global erro6
        global erro7
        u = randn(N2)*sqrt( $\sigma_u^2$ )
        x = filt(g, u)
        v = randn(N2)*sqrt( $\sigma_v^2$ )
        y5 = filt(h5, x)
        y6 = filt(h6, x)
        y7 = filt(h7, x)
        d5 = y5 .+ v
        d6 = y6 .+ v
        d7 = y7 .+ v
        w5, erro5 = LMS(x, d5, M,  $\mu_2$ )
        w6, erro6 = LMS(x, d6, M,  $\mu_2$ )
        w7, erro7 = LMS(x, d7, M,  $\mu_2$ )
        w_lms5 += w5
        w_lms6 += w6
        w_lms7 += w7
        erro5 += erro5.*erro5
        erro6 += erro6.*erro7
        erro7 += erro7.*erro6
    end

    w_lms5 = w_lms5./realizacoes2
    w_lms6 = w_lms6./realizacoes2
    w_lms7 = w_lms7./realizacoes2
    erro5 = erro5./realizacoes2
    erro6 = erro6./realizacoes2
    erro7 = erro7./realizacoes2
    noprint
end

```



Nesse exemplo conseguimos ver que os valores simulados ainda tendem para os mesmos valores obtidos anteriormente, mas por ter um sinal mais complexo que um ruído puro, o tempo de convergência é bem maior

Functions

LMS (generic function with 1 method)

```
• function LMS(x, d, M, μ)
•     N = length(x)
•     X = zeros(M,1)
•     W = zeros(N,M)
•     erro = zeros(N,1)
•
•     for n in 1:N-1
•         X = [x[n]; X[1:M-1]]
•         y = W[n,:]'*X
•         erro[n] = d[n]-y
•         W[n+1, :] = W[n,:] + μ*erro[n]*X
•     end
•     return W, erro
• end
```

noprint =

```
• noprint = md""
```